

멀티모달 AI 분석과 자기 투영 영상을 활용한 개인 맞춤형 감정 객관화 플랫폼

김다경, 박성진, 정재영, 차한규, 김병서

홍익대학교 소프트웨어융합학과

e-mail : {alice3976, c19262, maria2004, sjw1111}@g.hongik.ac.kr, {jsnbsg}@g.hongik.ac.kr

A Personalized Emotion-Objectification Platform via Multimodal AI Analysis and Self-Projected Avatar Videos

Da-gyeong Kim, Sung-jin Park, Jae-young Jung, Han-gyu Cha, and Byung-Seo Kim

Hongik University

Abstract

This paper proposes Otto, a personalized emotion-objectification platform that combines multimodal data analysis with the psychological concept of self-distancing. The system integrates speech, facial, and textual signals while establishing a per-user emotional baseline through an initial calibration phase, and infers affective states from the relative deltas (Δ) against this baseline rather than from absolute values. The estimated emotional trajectory is then transformed into a short-form avatar video that projects the user's persona, allowing the user to observe their own day from a third-person perspective and thereby invoke the self-distancing effect. A counseling module fine-tuned on expert dialogue data (SFT) provides empathetic and personalized support. We further propose a three-fold evaluation framework consisting of clinical indices (PHQ-9, PSS), behavioral indices, and an emotion-objectification index defined as the reduction in the gap between users' self-reported affect and the AI-inferred

objective values. a three-fold evaluation framework consisting of clinical indices (PHQ-9, PSS), behavioral indices, and an emotion-objectification index defined as the reduction in the gap between users' self-reported affect and the AI-inferred objective values..

I. 서론

최근 2030 세대를 중심으로 MBTI와 같은 성격 유형 검사가 폭 넓게 소비되는 현상은, 자신과 타인의 성향을 탐구하려는 강한 욕구를 반영한다. 그러나 이러한 관심에도 불구하고 국내 우울증 환자는 연간 100만 명을 넘어섰으며, 환자의 70%~80%가 자신의 정서 상태를 정확히 인식하지 못하는 '정서적 객관화의 부재'가 심각한 문제로 대두되고 있다.[1]. 또한 기존의 감정 기록 서비스 대부분은 이모티콘 선택이나 단순 텍스트 입력에 의존하여, 감정의 근거를 추적하기 어렵고 주관적 편향에 매몰될 위험이 크다. 본 연구는 이러한 한계를 극복하기 위해 심리학의 '자기 거리두기(Self-distancing)' 개념에 주목한다. 자기 거리두기란 자신의 경험을 다룰 때 한 발짝 물러나 관조적으로 바라보는 행위로, 제3자의

관점에서 자신의 경험을 재구성할 때 부정적 정서 반응이 감소하고 건설적 사고가 가능해지다는 점이 다수의 실증 연구에서 보고되었다[2][3]. 본 연구는 이 이론을 기술적 형태로 구현하기 위해, 사용자의 일상 대화를 멀티모달로 분석한 뒤 그 결과를 사용자 자신의 페르소나가 투영된 '쏫 폼 아바타 영상'으로 재구성하여 제공한다.

기존 멀티모달 감정 인식 연구는 사전 학습된 모델의 절대 수치(예: 분노 0.7)를 그대로 활용하는 경향이 강하지만, 표정과 목소리의 표현 강도는 개인차가 크기 때문에 절대값 기반 분석은 오인식의 위험이 높다. 본 연구는 이를 보완하기 위해 개인별 베이스라인(Baseline) 캘리브레이션과 상대적 변화량 추적 기법을 도입하여 분석의 객관성을 확보한다. 본 논문의 구성은 다음과 같다. 2장에서는 자기 거리두기 이론과 멀티모달 감정 인식, 생성형 AI 아바타에 관한 연구를 검토한다. 3장에서는 제안 플랫폼 '오토(Otto)'의 전체 아키텍처와 베이스라인 구현, 멀티모달 분석, 쏫 폼 영상 생성, SFT 상담 모듈을 차례로 기술한다. 4장에서는 결론과 함께 평가 지표 및 향후 연구 방향을 제시한다.

II. 관련연구

2.1 자기 거리두기과 디지털 치료제

Kross 등은 자신을 1인칭 '나'가 아닌 3인칭으로 호명하는 단순한 언어적 변화만으로도 감정 조절(emotion regulation) 효과가 발생함을 보고하였다[2]. Ayduk과 Kross는 자기 거리두기가 상태불안을 완화하고 자기성찰 수준을 높이는 데 유의미한 효과가 있음을 실증적으로 입증하였다[3]. 이러한 이론적 토대는 디지털 치료제(DTx) 영역에서 회상·관찰 기반 자기성찰 콘텐츠를 설계하는 근거로 활용된다. 그러나 기존 DTx 서비스는 텍스트 회고 중심이라 시각적 거리감 형성이 제한적이라는 한계가 있다.

2.2 멀티모달 감정 인식

감정 인식 연구는 단일 모달리티(텍스트, 음성, 얼굴) 분석을 거쳐 멀티모달 융합 방식으로 발전해 왔다. 얼굴 표정 분석은 Ekman의 FACS(Facial Action Coding System)[4]를 이론적 기반으로 삼으며, MediaPipe Face Mesh와 같은 도구는 468개의 안면 랜드마크를 실시간으로 추출하여 미세 표정 분석을 가능하게 한다. 음성 측면에서는 기본 주파수(F0),

강도, 발화 속도 등의 운율 특성(prosodic features)이 정서 상태와 유의한 상관을 갖는 것으로 알려져 있다[5]. 텍스트 분석은 STT(Speech-to-Text) 기반 전사 후 LLM이 문맥적 감정 키워드를 도출하는 방식이 보편화되어 있다.

2.3 자기 거리두기과 디지털 치료제

Text-to-Video(TTV) 분야에서는 Runway Gen-2, OpenAI Sora 등 디퓨전 기반 모델이 텍스트 시나리오로부터 짧은 영상을 합성하는 성능을 보이고 있으며, LivePortrait·SadTalker 와 같은 모델은 단일 정지 이미지와 음성으로부터 자연스러운 입모양과 표정을 생성한다. 본 연구는 분석된 감정 흐름을 시나리오로 변환한 뒤 TTV 모델로 시각화하여, '자신을 외부에서 관찰하는 경험'을 사용자에게 제공한다.

III. 제안시스템

본 장에서는 제안 플랫폼 '오토(Otto)'의 전체 흐름과 핵심 기술 요소를 기술한다. 오토는 사용자의 멀티모달 입력을 받아 (1) 베이스라인 캘리브레이션, (2) 멀티모달 분석 및 변화량(Δ) 산출, (3) 쏫 폼 시나리오 및 영상 생성, (4) SFT 기반 상담 대화의 네 단계로 구성된다. 시스템 전체 구조는 그림 1과 같다.




그림 1. 오토(Otto) 시스템 전체 구조

3.1. 자기 거리두기과 디지털 치료제

정확한 감정 분석을 위해서는 사용자별 표현 특성을 반영한 기준점이 필수적이다. 오토는 서비스 첫 사용 시 약 1분간의 '중립 대화 시나리오'를 제시하여 사용자의 평소 상태를 샘플링한다. 음성에서는 평균 기본 주파수(F0_mean), 변동 폭(F0_std), 발화 속도(syllable/sec), 음성 강도(intensity)를 추출하고, 안면에서는 MediaPipe 기반 468개 랜드마크의 평균

위치 및 분산을 산출한다. 또한 축소된 빅파이버(Big Five) 10문항과 인구통계 문항을 결합하여 성격 특성에 따른 감정 변화 민감도를 보정 계수로 모델에 반영한다.

이렇게 수집된 데이터는 사용자 프로파일 테이블 baseline_profile에 저장되며, 이후 모든 분석은 다음 식과 같이 베이스라인 대비 상대적 변화량으로 재정의된다.

$$\Delta_{emotion}(t) = f(x_t - \mu_{baseline}) / \sigma_{baseline} \quad (1)$$

여기서 x_t 는 시점 t 의 멀티모달 특성 벡터, $\mu_{baseline}$ 와 $\sigma_{baseline}$ 는 베이스라인의 평균과 표준편차이다. 절대 수치가 아닌 표준화된 변화량을 사용함으로써, ‘평소에 톤이 높은 사용자’와 ‘평소에 톤이 낮은 사용자’가 동일한 분노 강도를 다르게 표현하더라도 동등한 감정 신호로 매핑할 수 있다. 베이스라인- Δ 분석의 전체 데이터 흐름은 그림 2와 같다.




그림 2. Baseline- Δ 분석 데이터 플로우

알고리즘 1. Baseline- Δ Multimodal Emotion Inference

```

Input :  $x_t$  (multimodal feature vector @ t)
       B (baseline {mu, sigma, big5})
Output:  $e_t$  (inferred emotion state)

1: for m in {face, voice, text} do
2:    $D_m \leftarrow (x_t[m] - B.mu[m]) / B.sigma[m]$ 
3: end for
4: w <- personalize_weights(B.big5)
5:  $e_t \leftarrow \text{softmax}(w * \text{concat}(D_{\text{face}}, D_{\text{voice}}, D_{\text{text}}))$ 
6: if incongruent( $D_{\text{face}}, D_{\text{voice}}, D_{\text{text}}$ ):
7:   SFT_Counseling.ask_clarifying()
8: persist(t,  $x_t$ , D,  $e_t$ ) -> PostgreSQL
9: return  $e_t$ 
  
```

그림 3. Baseline- Δ 멀티모달 Emotion Inference 알고리즘

3.2. 비언어적 표현의 멀티모달 분석

정교한 감정 인식을 위해 본 시스템은 표 1과 같이 세 모달리티에서 각각의 특성을 추출한 뒤,

베이스라인 대비 Δ 값을 산출하여 융합한다.

표 1. 모달리티별 입력 특성과 Δ 산출 방식

모달리티	주요 라이브러리	추출 특성	Δ 산출
안면 표정	MediaPipe FaceMesh	468 랜드마크, FACS AU1-4·12·15	AU 강도의 z-score
음성 운율	librosa, pyAudioAnalysis	F0, RMS, 발화속도, jitter, shimmer	$\mu \cdot \sigma$ 대비 표준편차
텍스트	Whisper STT, KoBERT, GPT-4o	감정 키워드, 문맥 임베딩	코사인 유사도 변화

3.2.1. 안면표정분석

MediaPipe Face Mesh로 추출한 안면 랜드마크에 FACS Action Unit 매핑을 적용해 AU1(눈썹 안쪽 올림), AU4(눈썹 찌푸림), AU12(입꼬리 올림), AU15(입꼬리 내림) 등 정서와 강한 상관성을 갖는 액션 유닛을 계측한다. 무표정 구간에서도 잠재 정서를 포착하기 위해, 베이스라인 대비 미세 변화(<5%)를 별도로 추적하는 ‘잠재 표정 검출기(Latent Expression Detector)’를 2차 분석으로 적용한다.

3.2.2. 음성분석

librosa 라이브러리를 사용해 F0, 에너지(RMS), 발화 속도, jitter·shimmer 등의 운율 특성을 100ms 윈도우로 추출한다. 추출된 특성은 베이스라인 분포에 대해 z-score로 표준화된 후, KoBERT 텍스트 임베딩과 결합되어 멀티모달 분류기에 입력된다.

3.2.3. 텍스트 분석 및 모순 감지

Whisper 기반 STT로 변환된 발화는 KoBERT 및 LLM(예: GPT-4o)을 통해 감정 키워드와 문맥 의미를 도출한다. 본 시스템은 단일 모달리티 결과의 단순 평균이 아닌, 모달리티 간 부조화 감지(Multimodal Incongruence Detection)를 수행한다. 예컨대 사용자가 ‘괜찮다’고 말하지만 음성 Δ 와 표정 Δ 가 부정 방향으로 큰 경우, 시스템은 이를 인지부조화 신호로 간주하여 후속 SFT 모듈이 역질문을 던지도록 트리거를 발생시킨다.

3.3. 숏폼 영상 시나리오 및 생성

하루 동안 누적된 감정 흐름과 대화 요약은 LLM 시나리오 생성기에 입력되어, 30~60초 길이의 숏폼

시나리오로 변환된다. 시나리오는 (1) 시간대별 장면 분할, (2) 각 장면의 정서 톤(긍정·중립·부정)과 변화 시점,

(3) 3인칭 내레이션 구조의 세 요소로 구성된다.

생성된 시나리오는 Text-to-Video 모델 (Runway Gen-2 또는 LivePortrait + Stable Video Diffusion)에 의해 사용자의 페르소나가 투영된 아바타 영상으로 합성된다. 사용자는 자신의 일상을 마치 관찰 예능 프로그램의 등장인물처럼 ‘제3자의 시선’에서 시청하게 되며, 이는 자기 거리두기 효과를 시각적으로 극대화하는 핵심 장치로 기능한다.

3.4. SFT 기반 상담 모듈

오토의 상담 모듈은 일반 LLM의 ‘무난한 공감’을 넘어, 임상 심리에 근거한 반응을 생성하도록 SFT(Supervised Fine-Tuning) 기법으로 학습된다. 학습 데이터는 AI Hub 감정 대화 말뭉치, K-EmoDB, 그리고 전문가 자문을 통해 구축한 인지행동치료(CBT) 기반 상담 사례로 구성된다. 모델은 다음 세 가지 출력 형태를 학습한다.

① 감정 라벨링: 사용자 발화의 핵심 감정을 명명하여 인식 격차를 줄인다. ② 인지 재구성 질문(Cognitive Reframing): 자동적 사고를 검토하도록 유도한다. ③ 행동 강령 제안: 감지된 부정적 정서 유형에 따라 호흡 훈련, 짧은 산책, 사회적 지지 자원 활용 등 구체적인 행동 지침을 제공한다.

3.5. 데이터 적재 및 평가 설계

분석 결과는 PostgreSQL(+ PostGIS)에 정형 데이터로 저장되며, 사용자 발화 임베딩 등 비정형 벡터는 ChromaDB에 이원적으로 관리된다. 베이스라인 프로파일, 시점별 Δ 수치, 시나리오 메타데이터, 사용자 자가 평가 점수가 모두 누적되어 장기 추세 분석과 평가 지표 산출의 근거가 된다.




그림 4. 사용자-앱-백엔드-AI 시퀀스 다이어그램

IV. 결론 및 향후 연구 방향

본 논문에서는 사용자의 주관적 감정 인식을 객관화하여 자기 이해와 정서 안정 개선을 돕는 멀티모달 플랫폼 ‘오토(Otto)’를 제안하였다. 제안 시스템은 베이스라인 캘리브레이션과 변화량 기반 분석으로 개인차에 강건한 감정 인식을 제공하고, 숏폼 아바타 영상을 통해 자기 거리두기 효과를 유도하며, SFT 기반 상담 모듈로 실질적 정서 지원을 가능하게 한다.

시스템의 유효성을 검증하기 위해 본 연구는 표 2와 같이 세 가지 다각적 지표를 제안한다. 첫째, 임상지표로서 PHQ-9(우울 증상 선별도구)와 PSS(지각된 스트레스 척도)의 사전·사후 점수 변화를 측정한다. 둘째, 행동지표를 통해 사용자의 감정 기록 빈도, 앱 체류 시간, 재방문율의 변화를 추적해 서비스의 심리적 수용도를 판단한다. 셋째, 감정 객관화 지표로서 사용자가 스스로 평가한 주관적 감정 수치와 AI 멀티모달 분석이 도출한 객관적 수치 간의 편차(Gap)가 시간이 지남에 따라 감소하는 비율을 측정한다. 이는 사용자가 자신의 정서 상태를 보다 정확히 직면하게 되었음을 정량적으로 시사한다.

표 2. 오토(Otto) 유효성 검증 지표 체계

지표	측정 도구	측정 시점	성공 기준
임상지표	PHQ-9, PSS	0주, 4주, 8주	평균 점수 유의 감소
행동지표	앱 로그 (체류, 빈도)	주차별 누적	주 3회 이상 기록 유지
객관화 지표	주관 - AI Δ 편차 평균	매 회기	4주 후 Gap ≥ 20% 감소

향후 연구에서는 (1) Realtime API와 Live2D 아바타 간의 입모양 동기화(Lip-sync) 정밀화, (2) 베이스라인 측정용 1분 시나리오의 심리측정학적 타당화, (3) 지역 단위 정서 상태를 시각화하는 ‘감정 지도(Emotion Map)’로의 확장을 계획한다. 본 연구는 기술적으로는 자기 거리두기 기법을 서비스화함으로써, 현대인의 정신건강을 지원하는 실용적 디지털 헬스케어 도구로 자리매김할 수 있을 것으로 기대된다.

4.1. 한계 및 윤리적 고려

본 연구의 첫 번째 한계는 베이스라인

캘리브레이션이 단 1분의 표본에 의존한다는 점이다. 사용자의 그날 컨디션이 평소와 크게 다를 경우 베이스라인 자체가 편향될 수 있으므로, 향후에는 첫 1주간 다중 캘리브레이션을 통해 평균값을 갱신하는 ‘적응형 베이스라인(Adaptive Baseline)’ 방식을 도입할 필요가 있다.

두 번째로, 본 시스템은 사용자의 표정과 음성 등 민감한 생체 데이터를 다루므로, 데이터 최소화 원칙에 따라 원본 영상·음성은 단말 측에서 특성 벡터로 변환한 후 즉시 폐기한다. 서버에는 베이스라인과 Δ 수치 등 비식별화된 분석 결과만이 저장된다. 또한 사용자가 우울·자해 위험 신호를 보일 경우 시스템은 자동 응답 대신 임상 자원(예: 자살예방 상담전화)을 안내하도록 설계되어, 디지털 치료제로서 지켜야 할 안전 가드레일을 명시적으로 구축한다.

세 번째로, 자기 거리두기 효과의 정량적 입증을 위해서는 충분한 표본 크기의 사용자 연구(IRB 승인 기반)가 요구된다. 본 연구진은 4주~8주 단위의 단일군 사전·사후 비교(Pre-Post) 연구를 우선 수행한 뒤, 후속 연구에서는 일반 감정 기록 앱과의 무작위 대조 시험(RCT)을 통해 효과 크기를 검증할 계획이다.

참고문헌

- [1] 보건복지부, “정신건강실태조사,” 2023.
- [2] E. Kross, E. Bruehlman-Senecal, J. Park, A. Burson, Dougherty, H. Shablack, R. Bremner, J. Moser, and O. Ayduk, “Self-talk as a regulatory mechanism: How you do it matters,” *Journal of Personality and Social Psychology*, vol.106, no.2, pp.304–324, 2014.
- [3] O. Ayduk and E. Kross, “From a distance: Implications of spontaneous self-distancing for adaptive self-reflection,” *Journal of Personality and Social Psychology*, vol.98, no.5, pp.809–829, 2010.
- [4] P. Ekman and W. V. Friesen, *Facial Action Coding System: A Technique for the Measurement of Facial Movement*, Consulting Psychologists Press, 1978.
- [5] B. Schuller, A. Batliner, S. Steidl, and D. Seppi, “Recognising realistic emotions and affect in speech: State of the art and lessons learnt from the first challenge,” *Speech Communication*, vol.53, no.9–10, pp.1062–1087, 2011.
- [6] A. Radford et al., “Robust Speech Recognition via Large-Scale Weak Supervision (Whisper),” *arXiv:2212.04356*, 2022.
- [7] S. Park et al., “KoBERT: Korean BERT pre-trained model,” SKTBrain, 2019.
- [8] J. Guo, D. Zhang, X. Liu, Z. Zhong, Y. Zhang, P. Wan, and D. Zhang, “LivePortrait: Efficient Portrait Animation with Stitching and Retargeting Control,” *arXiv:2407.03168*, 2024.
- [9] K. Kroenke, R. L. Spitzer, and J. B. W. Williams, “The PHQ-9: validity of a brief depression severity measure,” *Journal of General Internal Medicine*, vol.16, no.9, pp.606–613, 2001.
- [10] S. Cohen, T. Kamarck, and R. Mermelstein, “A global measure of perceived stress,” *Journal of Health and Social Behavior*, vol.24, no.4, pp.385–396, 1983.
- [11] A. T. Beck, *Cognitive Therapy and the Emotional Disorders*, International Universities Press, 1976.
- [12] AI Hub, “감정 분류용 한국어 멀티모달 데이터셋(K-EmoDB 외),” 한국지능정보사회진흥원, 2022.
- [13] T. Baltrusaitis, C. Ahuja, and L.-P. Morency, “Multimodal Machine Learning: A Survey and Taxonomy,” *IEEE Trans. Pattern Analysis and Machine Intelligence*, vol.41, no.2, pp.423–443, 2019.
- [14] L. Ouyang et al., “Training Language Models to Follow Instructions with Human Feedback,” *NeurIPS*, 2022.
- [15] M. McFee et al., “librosa: Audio and Music Signal Analysis in Python,” *Proc. of the 14th Python in Science Conference*, pp.18–25, 2015.